

LAPORAN RINGKASAN EKSEKUTIF PENELITIAN

Analisis Komparatif Imputasi Data Hilang & Audit Forensik Target Leakage pada Prediksi Diabetes (Kohort PIMA)

Peneliti: Mitchel Mohamad
Dosen Pembimbing: Bu Yunen
Status Dokumen: Final (Siap Sidang & Jurnal)

Target Luaran: Paper Jurnal Nasional / Internasional Bereputasi
Tanggal Rilis: Oktober 2026 (Audit v2 Selesai)
Repositori GitHub: mitcheltastic/DiabeticAnalysis

1. Ringkasan Eksekutif: Nilai Hakiki Kejujuran Metodologis

Dalam penelitian *machine learning* medis, **angka akurasi yang lebih rendah namun jujur dan metodologinya benar bernilai seribu kali lebih tinggi daripada angka tinggi semu yang diperoleh dari kebocoran data (target leakage)**. Angka tinggi semu (~88% - 89%) akan langsung gugur saat diuji oleh penguji sidang atau reviewer jurnal internasional yang teliti. Sebaliknya, membongkar cacat data, mereplikasi hasil terdahulu secara presisi, dan menetapkan benchmark *leak-free* yang kokoh adalah **kontribusi ilmiah kelas satu**.

Alur Cerita & Roadmap Temuan Ilmiah:

- Replikasi Baseline Paper:** Berhasil mereplikasi baseline XGBoost paper kakak kelas tepat **0.8506** (131/154 pasien).
- Audit Data Higienis:** Menemukan 5 nilai glukosa bernilai 0 mg/dL yang terlewat di seluruh 5 file imputasi lama.
- Forensik Leakage RLTR:** Membuktikan matematis kebocoran target pada file RLTR ($t = 26.77$, $r = 0.7908$).
- Benchmark Leak-Free:** 50-fold cross-validation & uji Nadeau-Bengio (Median imputation paling tangguh & defensibel).
- Restorasi Klinis (SHAP):** Glukosa kembali ke Rank #1 dan BMI ke Rank #3 (kebenaran medis tegak kembali).
- Optimasi Skrining Medis:** Menurunkan threshold ke 0.37 meningkatkan sensitivitas klinis dari 59% ke 79.85%.
- Hasil Akhir Holdout Murni:** Akurasi murni 74.68% (AUC 0.8135), uji McNemar $p = 0.0004$ konsisten dengan leakage.

2. Latar Belakang Klinis & Temuan Cacat Data (5 Glukosa Nol)

Dataset PIMA Indians terdiri dari 768 wanita (500 sehat, 268 diabetes). Pada tubuh manusia yang hidup, nilai tekanan darah, ketebalan lipatan kulit, insulin, dan glukosa **tidak mungkin bernilai nol**. Angka nol ini adalah data hilang: **Insulin hilang 48.70% (374 pasien)** dan **Skinfold hilang 29.56% (227 pasien)**. Namun audit mendalam kami mengungkap temuan kritis:

- Bug 5 Glukosa Nol:** Kelima file imputasi terdahulu (LTR, NSSR, RLTR, SIM, TR) mengimputasi insulin dan skinfold, namun **sama sekali melewatkan glukosa** (5 pasien tetap 0 mg/dL: Index 75, 182, 342, 349, 502).
- Dampak Fatal:** Glukosa adalah prediktor utama diabetes ($F = 245.67$). Angka nol memaksa pasien diabetes 349 dan 502 masuk ke daun sehat pada pohon keputusan, menciptakan *false negative* permanen.
- Solusi Kita:** Melakukan imputasi otomatis median glukosa (117 mg/dL) yang segera menstabilkan pohon keputusan.

3. Replikasi Presisi Baseline Kakak Kelas & Mitos Angka '0.88'

Kami mereplikasi metodologi paper kakak kelas: Default XGBoost pada RLTR, split 80:20 (random_state=42, N_test=154). Hasil eksekusi script kami **mereplikasi angka paper tepat hingga 1 pasien**: Akurasi **0.8506** (TN=90, FP=10, FN=13, TP=41, Sensitivitas 0.7593, Spesifisitas 0.9000, F1 0.7810).

Mitos 0.88 Terjawab: Di paper resmi kakak kelas tidak pernah tertulis angka 0.88. Angka 0.8831 (dan 0.8961 pada consensus ensemble) hanya muncul bila pengujian dilakukan pada split acak tertentu (seed 12). Pada sampel uji N=154, margin of error split mencapai $\pm 5.5\%$. Uji McNemar menunjukkan $p = 0.7539$ (tidak ada perbedaan signifikan antara model paper dan model consensus pada split yang sama).

4. Pembongkaran Ilmiah: Bukti Matematis Target Leakage pada RLTR

Pada uji awal, RLTR mendadak melompat sendiri ke akurasi 85.02% (sementara 5 file lainnya berada di 76% - 78%). Audit matematis kami membuktikan bahwa **label target Outcome bocor ke dalam perhitungan imputasi insulin**:

Uji Statistik	Data Klinis Asli (N=394)	File RLTR Bocor (N=374)	Eksperimen Rekonstruksi	Makna / Vonis Ilmiah
Koefisien Regresi Outcome	-5.72 mg/dL	+28.68 mg/dL	+29.08 mg/dL	Suntikan buatan +28.68 mg/dL pada pasien diabetes!
Nilai t-statistic Outcome	$t = -0.45$ ($p = 0.653$)	$t = 26.77$ ($p < 10^{-75}$)	$t = 27.60$ ($p < 10^{-75}$)	Pada tubuh riil tidak signifikan; di RLTR bocor masif.
Korelasi Parsial $r(\text{Ins, Y} \mid \text{Gluc, BMI})$	$r = -0.0168$ ($p = 0.740$)	$r = +0.8208$ ($p < 10^{-90}$)	$r = +0.8262$ ($p < 10^{-90}$)	Sinyal diagnostik palsu tertanam di insulin.
Korelasi Insulin dg Target (r)	$r = 0.3014$	$r = 0.7895$	$r = 0.7908$	Rekonstruksi kita cocok persis (selisih 0.0013)!

5. Benchmark Murni Leak-Free & Uji Statistik Nadeau-Bengio (50 Folds)

Pada pengujian 50-fold cross-validation murni tanpa kebocoran (imputasi dan scaling dilakukan ketat di dalam fold latih), kami mengevaluasi signifikansi menggunakan **Nadeau-Bengio corrected resampled t-test** dengan koreksi **Holm-Bonferroni**:

Metode Imputasi	Akurasi 50-Fold (Mean ± Std)	ROC-AUC	Selisih vs Median	Nadeau-Bengio 95% CI	Holm p-value	Signifikan vs Median?
MissForest (ExtraTrees)	0.7705 ± 0.0486	0.8431	+0.0112	[-0.0051, +0.0275]	p = 0.8751	Tidak (CI lewat 0)
MICE (BayesianRidge)	0.7726 ± 0.0549	0.8415	+0.0073	[-0.0077, +0.0222]	p = 1.0000	Tidak (CI lewat 0)
Honest RLTR (eps=0.25)	0.7671 ± 0.0504	0.8407	+0.0039	[-0.0116, +0.0193]	p = 1.0000	Tidak (CI lewat 0)
KNN (k=5)	0.7692 ± 0.0454	0.8372	+0.0029	[-0.0151, +0.0208]	p = 1.0000	Tidak (CI lewat 0)
Median Baseline	0.7676 ± 0.0425	0.8361	Reference	Reference	Reference	Baseline Paling Tangguh

Kesimpulan Ilmiah: Tidak ada metode imputasi kompleks yang secara signifikan mengungguli imputasi median sederhana (seluruh confidence interval mencakup nol). Imputasi median adalah baseline paling defensibel.

6. Feature Ablation, Restorasi Medis (SHAP) & Optimasi Skrining

- **Uji Ablasi Fitur (Parsimoni):** Uji 10-fold nested CV membuktikan bahwa fitur buatan seperti HOMA-IR (delta = -0.0065, CI [-0.0166, +0.0035]) dan interaksi lainnya memiliki CI yang melintasi nol. Maka dari itu, **8 fitur klinis asli adalah yang paling optimal**.
- **Restorasi Kebenaran Medis melalui SHAP:** Pada data bocor, Insulin salah ditempatkan di ranking #1. Pada model leak-free kita, **Glukosa kembali menjadi nomor #1**, dan **BMI naik ke nomor #3**, memulihkan konsistensi fisiologi endokrinologi.
- **Optimasi Skrining Medis:** Ambang batas default (0.50) hanya mendeteksi 58.97% penderita diabetes. Dengan mengkalibrasi threshold keputusan ke **0.37**, sensitivitas klinis melompat menjadi **79.85% (+20.9 pp)** dengan F1 optimal **0.7063**.

7. Evaluasi Akhir pada Untouched Holdout Test Set (N=154)

Protokol Evaluasi	Akurasi Holdout [95% CI]	Sensitivitas	Spesifisitas	F1-Score	ROC-AUC	Uji McNemar vs Baseline
Baseline Paper (RLTR Bocor)	0.8506 [0.792 - 0.903]	0.7593	0.9000	0.7810	0.8931	Baseline Reference
Consensus Demo (Seed 12)	0.8961 [0.844 - 0.942]	0.8333	0.9300	0.8491	0.9328	p = 0.7266 (Netral)
Frozen Leak-Free Pipeline (Seed 42)	0.7468 [0.675 - 0.818]	0.5741	0.8400	0.6139	0.8135	p = 0.0004 (Signifikan)

Makna Akademis Uji McNemar (p = 0.0004): Selisih performa antara baseline lama dengan pipeline leak-free kita terbukti signifikan secara statistik dan **konsisten dengan adanya kebocoran data dan kontaminasi pra-split**.

8. Empat Pilar Kontribusi Ilmiah untuk Bu Yunen & Kesiapan Publikasi

Empat Pilar Utama Paper:

- Replikasi Sempurna:** Menunjukkan integritas ilmiah dengan mereplikasi baseline paper terdahulu tepat 100% (0.8506, TN=90, FP=10, FN=13, TP=41).
- Koreksi Data (Bug Fix):** Menemukan dan memperbaiki 5 glukosa nol yang selama ini luput di semua dataset pembanding.
- Audit Target Leakage (Poin Emas):** Membuktikan matematis kebocoran data pada RLTR (t = 26.77) dan merekonstruksi mekanismenya (r = 0.7908). Temuan forensik ini bernilai tinggi untuk jurnal bereputasi.
- Standar Leak-Free yang Sahih:** Menetapkan batas akurasi riil PIMA di 76.5% - 77.5% (AUC 0.845) dengan validasi Nadeau-Bengio dan optimasi threshold skrining.

Semua skrip deterministik (run_phase1.py s.d. run_phase6.py) dan gambar publikasi tersimpan rapi dan tersinkronisasi di [GitHub](#).

9. Lampiran Galeri Visual Ilmiah Utama (Visual Exhibits)

Berikut adalah 4 visualisasi utama yang dihasilkan oleh pipeline kami dan siap digunakan untuk presentasi sidang dan naskah jurnal bersama Bu Yunen:





Exhibit A: Heatmap Benchmark 50-Fold Repeated CV (Metode Imputasi × Model)

Exhibit B: Kurva ROC-AUC Multi-Model & Consensus Ensemble (Permintaan Bu Yunen)





Exhibit C: Confusion Matrix Consensus Model Holdout (Permintaan Bu Yunen)

Exhibit D: Ranking Global SHAP Leak-Free (Glukosa Kembali ke Rank #1)




Exhibit E: Kurva Tradeoff Threshold Operasional Skrining Klinis (Optimal F1 pada Threshold = 0.37, Sensitivitas 79.85%)